

AVALIANCE COPILOT

Avaliance Copilot — Document Intelligence Souveraine

Plateforme souveraine de document intelligence pour la recherche documentaire et la génération de propositions RFP/RAG.

Recherche instantanée

Retrouvez rapidement les informations et références clés.

Confidentialité renforcée

Vos données restent dans un environnement souverain sécurisé.

Réponses de confiance

Produisez des livrables sourcés, clairs et traçables.

Le besoin métier : trouver une information fiable et produire plus vite

Avaliance Copilot aide un consultant à exploiter une base documentaire interne pour retrouver la bonne information, la vérifier et l'utiliser rapidement dans une proposition commerciale.

Le problème

- Les informations sont dispersées dans de nombreux PDF et formats.
- Il faut distinguer les contenus fiables, récents et vraiment utiles.
- Une réponse imprécise peut faire perdre du temps ou créer un risque.

Les deux parcours



Recherche documentaire

Retrouver rapidement une information précise et son contexte utile dans les documents internes.



Génération de proposition RFP

Produire une première version structurée à partir d'un brief, en s'appuyant sur la base documentaire.

ARCHITECTURE SOUVERAINE

AUTO-HÉBERGÉE

SANS API LLM EXTERNE

Une architecture souveraine, séparée par responsabilités

Frontend React

Interface utilisateur auto-hébergée, dédiée à la navigation documentaire, aux requêtes de recherche et à la génération de propositions.

Backend Spring

API métier locale qui centralise l'authentification, les droits d'accès et l'orchestration des appels internes.

Service FastAPI


Microservice interne dédié aux opérations RAG : récupération de contexte, préparation des passages pertinents et assemblage des réponses.

Postgres + Ollama

Couche locale de stockage et d'inférence, sans dépendance externe.

- ❑ Le principe clé : chaque couche a un rôle clair, et rien ne sort du périmètre hébergé. Données, authentification et génération restent entièrement sous contrôle interne.

Du document source à une base de connaissances exploitable



Flux de statut : STORED → PROCESSING → INDEXED / FAILED

- **Limite d'import :** 20 Mo
- **Traçabilité :** empreinte SHA-256
- **Chunking :** segments d'environ 850 caractères
- **Vectorisation :** embeddings BGE-M3 en 1024 dimensions

Comment fonctionne le RAG : retrieval hybride et preuves préservées

Le RAG combine recherche sémantique et recherche lexicale pour capter le sens et les termes exacts.
La fusion puis le reranking sélectionnent les meilleures preuves en conservant les sources utiles.

1

Question

Reformulation de la requête.

2

Encoding

bge-m3 crée les embeddings.

3

Parallel Search

Sémantique + lexicale en parallèle.

4

Fusion

RRF combine les classements.

5

Reranking

bge-reranker-v2-m3 trie les candidats.

6

Selection

Preuves retenues avec sources.

Recherche sémantique

Retrouve les passages proches par le sens.

- Paraphrases et synonymes
- Compréhension de l'intention


Recherche lexicale

Retrouve les termes exacts et les mots-clés.

- Acronymes et noms propres
- Citations et références

Parcours 1 : recherche documentaire sourcée et contrôlée

Le consultant pose une question en français avec des filtres métier. Le frontend envoie la requête au backend authentifié, puis le service IA recherche des passages pertinents dans les PDF administrés.



Parcours 2 : proposition RFP fondée sur le brief et les preuves PDF

Le parcours transforme un brief commercial en réponse structurée, argumentée et contrôlée. Il sélectionne les meilleures preuves PDF puis rédige une proposition cohérente, orientée livrable et prête à être consolidée en réponse RFP.


1	2	3	4
Synthèse exécutive Résumé de la demande, angle de réponse, bénéfices clés et message de positionnement.	Compréhension du besoin Lecture structurée du brief, reformulation des enjeux, contraintes, priorités et critères implicites.	Solution et périmètre Description de l'approche proposée, des lots couverts, des exclusions et des hypothèses de cadrage.	Démarche et livrables Phases d'intervention, méthode, jalons, livrables attendus et modalités de mise en œuvre.
5	6		
Sécurité / risques / hypothèses Points de vigilance, dépendances, arbitrages, risques projet et hypothèses structurantes.	Fit Avaliance & prochaines étapes Valeur ajoutée, adéquation au contexte client, éléments de différenciation et suite du process.		

Processus de génération RFP :



Déploiement AWS : une plateforme GPU reproductible et sécurisée

g4dn.xlarge · 4 vCPU · 16 Go RAM · GPU NVIDIA Tesla T4



01

1. Préparer l'environnement

03

3. Démarrer PostgreSQL et Ollama

05

5. Lancer les contrôles finaux

02

2. Valider la configuration Compose

04

4. Démarrer la pile complète

